

Santélia — Configuration des 3 nœuds Proxmox

Document diffusable Dépôt : santelia-iac — Dernière mise à jour :
05/10/2026

1. Objet du document

Ce document décrit la configuration retenue pour la brique **Proxmox VE HA** du projet Santélia, dont le rôle est d'héberger les VM critiques dans une architecture de haute disponibilité afin de limiter les interruptions de service.

Statut : cluster **créé et opérationnel** (quorate, trois nœuds, anneaux de communication vérifiés). La réplication et le groupe de haute disponibilité sont opérationnels.

Cette brique répond à l'exigence n° 1 du cahier des charges, classée **Must** : « Accès continu au DPI via haute disponibilité des VM ».

2. Écarts assumés

À déclarer explicitement dans la recette, puisqu'elle doit démontrer la conformité de façon objective.

Écart	Justification	Impact
Les 3 nœuds sont hébergés sur une seule machine physique	Contrainte matérielle du laboratoire	La maquette démontre le mécanisme de quorum, de réplication et de bascule, pas la résistance à une panne physique de l'hôte
Pare-feu Proxmox désactivé host_key_checking = False côté Ansible	Simplification de l'environnement de test Environnement de test	À activer en production Écart de sécurité documenté, à corriger en production
Aucun swap dans les nœuds	Comportement Proxmox par défaut sur ZFS	Acceptable pour des nœuds de laboratoire, à

Écart	Justification	Impact
ZFS en RAID0 (disque unique) par nœud	Un seul disque virtuel par nœud	surveiller Aucune redondance au niveau du pool ; le pool sert à la réplication, pas à la tolérance de panne
Un seul chemin de communication de cluster	Configuration par défaut	Pas de redondance du lien de quorum si le réseau d'administration vacille

3. Architecture

Un hyperviseur physique héberge **trois nœuds Proxmox VE imbriqués**, virtuellement séparés.

Nœud	Rôle	vCPU	RAM	Disque
pve-a	Nœud principal	2	4 Gio	24 Gio
pve-b	Nœud secondaire	2	4 Gio	24 Gio
pve-c	Votant de quorum	2	4 Gio	24 Gio

Pourquoi trois nœuds et pas deux

Le quorum Corosync exige une **majorité stricte**. À trois nœuds, la majorité est de deux : perdre un nœud laisse le cluster opérationnel. À deux nœuds, il faudrait ajouter un **QDevice** externe pour obtenir cette même majorité.

Le choix de trois nœuds supprime donc le besoin d'un QDevice, d'un export NFS comme stockage partagé, et de toute la complexité qui va avec.

Pourquoi les trois nœuds sur la même machine

Les trois nœuds partagent un processeur identique, ce qui autorise l'exposition du **type CPU natif** et supprime toute contrainte de compatibilité pour la migration à chaud. Un nœud placé sur une seconde machine physique, de

génération différente, aurait imposé un modèle de CPU conservateur au détriment des performances.

4. Prérequis techniques

Activation de la virtualisation imbriquée

L'hôte doit exposer les instructions de virtualisation matérielle à ses invités, sinon un nœud démarre mais **refuse de lancer ses propres machines virtuelles**.

Vérification : le paramètre nested du module KVM doit valoir Y.

Paramétrage des VM

Paramètre	Valeur	Justification
Type de CPU	Natif	Sans lui, le nœud démarre mais ne peut pas virtualiser
Gestion mémoire dynamique	Désactivée	Comportement erratique dans un hyperviseur déjà virtualisé
Discard	Activé	Permet au stockage thin de récupérer les blocs libérés
Démarrage automatique	Activé	Les nœuds reviennent après un redémarrage de l'hôte
Deux cartes réseau	—	Une pour l'administration, une pour le réseau de service

Plafonnement du cache ZFS

ZFS consomme par défaut jusqu'à la moitié de la RAM disponible en cache. Sur trois nœuds de 4 Gio, cela provoque une saturation mémoire. Le cache est donc plafonné à **512 Mio par nœud**.

5. Stockage

Hôte physique

Volume	Taille	Rôle
Système	69 Gio	Système d'exploitation, modèles de conteneurs, images ISO
Thin pool	141 Gio	Disques des machines virtuelles
Sauvegardes	60 Gio libres	Sauvegardes vzdump
Disque annexe	245 Gio	Réservé à un autre projet, hors périmètre

Les disques des nœuds sont créés dans le **thin pool**, ce qui permet de sur-allouer : un disque de 24 Gio annoncé n'occupe que l'espace réellement écrit.

Nœuds

Chaque nœud est installé en **ZFS sur disque unique**.

Ce choix n'est pas guidé par la redondance, mais par le **nom du pool**. Proxmox nomme systématiquement son pool système de la même façon, ce qui rend la **réplication native entre nœuds** possible. C'est ce mécanisme qui permettra à une VM de redémarrer sur un nœud survivant.

Capacité utile constatée : environ **20,8 Gio** sur les 24 Gio alloués, ZFS réservant près de 13 % pour ses métadonnées.

6. Réseau

Interface	Rôle
Administration	Accès web et SSH aux nœuds, trafic de cluster Corosync
Service	Segment L2 commun aux instances du service applicatif

La séparation en deux plans répond à deux besoins distincts. Le réseau d'administration supporte l'exploitation et le clustering, le réseau de service supporte la continuité applicative.

Point d'attention : L2 obligatoire pour Corosync

Corosync échange ses votes en multicast sur le même segment de niveau 2. Il ne doit **jamais** traverser un NAT, sous peine de votes fantômes et de pertes de quorum inexpliquées.

Accès distant

Les nœuds imbriqués ne sont pas des machines indépendantes sur le réseau. L'administration à distance s'effectue par **rebond SSH** via l'hôte physique, ce qui fonctionne aussi bien sur le réseau local qu'à distance.

Adressage

Six adresses statiques sont nécessaires : trois pour les nœuds, trois réservées à l'avance pour les futurs services. Elles doivent être **exclues de la plage DHCP** du réseau pour éviter tout conflit.

7. Procédure de duplication d'un nœud

Le clonage d'une machine virtuelle duplique son identité. Trois éléments doivent impérativement être régénérés dans chaque clone, **avant tout test de connexion**.

Élément	Risque si dupliqué
Clés d'hôte SSH	Rejet des connexions, alertes de sécurité, échec du clustering
Identifiant machine	Comportements erratiques des services, traces ambiguës
Adresse réseau	Conflit d'adresses, coupures intermittentes

Procédure

1. Renommer la machine.
2. **Supprimer** les clés d'hôte existantes.
3. Les régénérer.
4. Régénérer l'identifiant machine.
5. Modifier l'adresse réseau et le fichier de résolution local.
6. Redémarrer le service SSH.

7. Redémarrer la machine.

Piège documenté

L'outil de génération de clés SSH ne régénère jamais une clé existante. Il crée uniquement les clés manquantes, et il reste totalement silencieux lorsqu'il n'a rien à faire.

Conséquence : si l'étape de suppression n'est pas exécutée, la commande ne produit rien et le clone conserve l'identité de la machine d'origine. C'est l'erreur la plus coûteuse de cette phase.

Bonne nouvelle sur l'identifiant machine

Sur une machine virtuelle, l'identifiant machine n'est pas tiré au hasard : il est **dérivé de l'identifiant unique exposé par l'hyperviseur**. Comme l'opération de clonage régénère cet identifiant, chaque clone dispose déjà du sien dès son premier démarrage. La régénération est donc une **ceinture de sécurité**, pas une urgence.

Symptômes d'une identité dupliquée

- Le client SSH signale que la clé du serveur est connue sous un **autre nom ou une autre adresse**.
- Une connexion SSH s'établit puis est coupée brutalement avant toute authentification.
- Le service SSH apparaît actif alors qu'il ne peut servir aucune connexion.

Vérification

Les empreintes de clés d'hôte de tous les nœuds doivent être **différentes**. Le commentaire associé à chaque clé indique le nom de la machine qui l'a générée, ce qui permet d'identifier immédiatement un partage d'identité.

8. Vérifications réalisées

Contrôle	Méthode	Résultat obtenu
Virtualisation imbriquée	Recherche du flag vmx dans le processeur	Présent, non nul sur les trois nœuds
Pool ZFS	État et nom du pool système	rpool en ligne, nom identique sur les trois

Contrôle	Méthode	Résultat obtenu
Espace disponible	Espace libre de chaque pool	nœuds ~21,5 Gio libres par nœud
Cache ZFS	Valeur du plafond en mémoire	512 Mio appliqués
Unicité des noms	Nom d'hôte de chaque nœud	Trois valeurs distinctes
Unicité des identités	Identifiants machine et empreintes SSH	Trois valeurs distinctes
Unicité réseau	Comparaison des adresses MAC déclarées et observées	Trois adresses distinctes, sans conflit
Accès automatisé	Connexion SSH sans mot de passe	Réussie sur les trois nœuds
Une adresse MAC identique observée sur deux nœuds peut provenir d'un cache réseau obsolète. Vider la table et réinterroger avant de conclure à un conflit réel. Un pont réseau hérite de l'adresse MAC de son premier port : c'est un comportement normal, pas un conflit.		

9. Création du cluster

Le cluster a été créé et assemblé le **05/10/2026**. Il est **quorate** avec trois nœuds participants.

Caractéristique	Valeur
Nom du cluster	santelia
Transport	knet
Authentification sécurisée	Activée
Nœuds	3
Votes attendus	3
Majorité requise (quorum)	2
État	Quorate

Déroulé de l'assemblage

Étape	Date	Version de configuration
Création sur le nœud principal	05/10 à 09:18	1
Jonction du 2e nœud	05/10 à 09:27	2
Jonction du 3e nœud	05/10 à 09:30	3

Bénéfice du quorum à deux sur trois

La perte d'un nœud laisse le cluster **opérationnel**. C'est précisément ce qu'apporte la solution à **trois nœuds** : une majorité atteignable sans dispositif externe. Une solution à deux nœuds aurait nécessité un **QDevice** supplémentaire pour obtenir la même résilience.

Piège rencontré, à documenter

La jonction d'un nœud échoue si le **fichier de résolution local** contient encore les informations de la machine d'origine. Deux problèmes constatés après clonage :

1. **L'adresse héritée** pointait vers le nœud source. Le cluster ne pouvait alors pas déterminer l'adresse locale de la machine, et refusait la jonction avec un message explicite.
2. **Le nom pleinement qualifié** contenait un caractère erroné, rendant la résolution incohérente avec le nom court de la machine.

Correction : la ligne de résolution locale doit associer **la bonne adresse** au **nom complet correct**, suivi du **nom court**. Le contrôle consiste à comparer nom court, nom complet et résolution par nom court : les trois doivent concorder.

Cette correction est le **quatrième effet du clonage**, après les clés d'hôte SSH, l'identifiant machine et l'adressage réseau. Elle justifie à elle seule l'automatisation de la procédure en phase de standardisation.

10. Contrôles post-crédation effectués

Contrôle	Résultat obtenu
État du cluster	Trois nœuds, trois votes, quorum à deux, indicateur « quorate »

Contrôle	Résultat obtenu
Liste des membres	Les trois nœuds présents, un vote chacun
Anneaux de communication Corosync	Tous les liens « connected », aucun paquet perdu
Cohérence des pools de réplication	Nom de pool identique sur les trois nœuds
Unicité des identifiants machine	Trois valeurs distinctes
Le contrôle des anneaux de communication Corosync est le plus souvent négligé. Il révèle les clusters qui fonctionnent en apparence mais perdent leur quorum sans explication au bout de quelques semaines. Il est recommandé de le systématiser après toute opération sur le cluster.	

11. État d'avancement

Élément	État
Hôte physique	Opérationnel, virtualisation imbriquée active
Trois nœuds Proxmox	Installés, identités uniques, administrables à distance
Cluster	Créé le 05/10/2026 , quorate à 3 nœuds, majorité à 2
Anneaux de communication	Tous les liens actifs
Réplication entre nœuds	Opérationnelle, état OK
Groupe de haute disponibilité	Configuré, ressource critique rattachée

Étapes suivantes

1. **Création du cluster** et jonction des trois nœuds — **fait le 05/10/2026**.
2. **Contrôle du quorum et des anneaux** : trois votes, majorité à deux, état « quorate », liens actifs.
3. **Réplication** des volumes entre nœuds.
4. **Groupe HA** et machine virtuelle de test.
5. **Démonstration de bascule** horodatée — voir le document « Test de recette HA ».

12. Cibles de recette associées

Test de recette défini par le cahier des charges

Brique	Test	Résultat attendu	Preuve exigée
HA / Proxmox VE	Simuler l'indisponibilité d'un nœud hébergeant une VM critique	Le service reste disponible ou est rétabli dans le délai cible	Compte rendu + horodatage
Sauvegarde / PBS	Lancer une sauvegarde puis tester une restauration	Sauvegarde exploitable et restauration réussie	Journal de sauvegarde + preuve de restauration
Supervision / Zabbix	Vérifier la remontée et déclencher une alerte	Les 30 postes visibles, alerte remontée correctement	Capture/export Zabbix + journal
IaC / Ansible	Déployer ou reconfigurer une machine de test, puis rejouer le playbook	Configuration identique et standardisée, sans action manuelle	Playbook + sortie d'exécution + état final

La recette vérifie chaque brique **séparément puis leur fonctionnement conjoint**, et les tests sont réalisés sur l'**environnement de validation avant la mise en production**.

Indicateurs complémentaires proposés

Ces indicateurs sont **proposés** et restent à valider.

Domaine	Indicateur	Cible proposée
Sauvegarde	RPO (perte de données maximale)	< 15 min
Sauvegarde	Temps de restauration d'une VM critique	< 30 min

Domaine	Indicateur	Cible proposée
Ansible	Temps de déploiement ou de reconfiguration	< 15 min
Zabbix	Réactivité des alertes vers la DSI	< 2 min

13. Rappel des exigences et priorités

#	Exigence	Priorité	Brique retenue
1	Accès continu au DPI via haute disponibilité des VM	Must	Proxmox VE HA
2	Sauvegarde 3-2-1 et restauration	Must	PBS + copie secondaire
3	Automatisation des serveurs et applications	Must	Ansible + playbooks
4	Supervision centralisée des 30 postes	Should	Zabbix

Les exigences **Must** sont traitées en priorité, en vérifiant que les options retenues restent compatibles avec l'enveloppe maximale de 15 000 €.

Les identifiants techniques détaillés (adressage complet, empreintes, identifiants machine) sont conservés dans une annexe interne non jointe à ce document.

Source : cahier des charges Santélia, Bloc 2 AIS — Groupe 2.